

Large Language Models e Engenharia de Prompts

Versão .NET 10 LTS / C# 14 — 3 horas

Agenda da aula

Como LLMs funcionam (intuição, sem fórmulas)

Catálogo de modelos no Foundry e critérios de escolha

Boas práticas de engenharia de prompts

Hands-on: comparativo de modelos e refino de prompts

Quiz + desafio

Como
funciona

Catálogo

Prompts

Hands-on

Quiz

Recap em 1 minuto

IA → ML → DL → GenAI (camadas)

GenAI cria conteúdo; LLM é GenAI especializada em texto

Foundry é nossa plataforma para construir

Tokens, modelos e prompts são o nosso vocabulário

De onde paramos

- GenAI cria...
- LLMs preveem o próximo token
- Foundry hospeda
- Prompt = sua interface com o modelo


Como um LLM gera texto (intuição)

Tokenização: texto vira tokens (BPE/tiktoken)

Modelo prediz a probabilidade do próximo token

Decodificação amostra o próximo token (controlada por parâmetros)

Não é busca, é geração probabilística condicional



Embeddings em uma frase

Vetor numérico de N dimensões que representa significado

Distância vetorial $\approx$ similaridade semântica

Modelos: text-embedding-3-small (1536d), large (3072d)

Mesmo modelo é usado para indexar e para buscar

Vetores de significado

- “banco” (instituição) • “banco” (sentar) • ...vivem em vetores diferentes! • Distância = quão próximos eles estão

Janela de contexto e custo

GPT-5.6 / GPT-5.5 $\approx$ 1M tokens; GPT-5.4-mini $\approx$ 400k

Cada token tem custo (input + output)

Truncar histórico é regra, não exceção

Em PT-BR, 1 token $\approx$ 3-4 caracteres

Janela

Quanto cabe por chamada

Custo

\$\$ por 1k tokens

Latência

Cresce com tokens

Decisão

Quanto contexto vale?


Mensagens system / user / assistant

system: define comportamento e persona; aparece 1× no início

user: pergunta ou tarefa do usuário

assistant: respostas do modelo (ou exemplos few-shot)

tool: respostas de ferramentas (function calling, Aula 7)



Parâmetros de geração

temperature: 0 (determinístico) → 1 (criativo)

top_p: nucleus sampling — alternativa à temperature

max_tokens: limite duro de saída

presence/frequency penalties: anti-repetição

seed: reprodutibilidade entre execuções

temperature

Aleatoriedade

top_p

Diversidade

max_tokens

Tamanho da saída

penalties

Evita repetição

Catálogo Foundry Models

GPT-5.6 / GPT-5.5: uso geral premium, multimodal

Raciocínio: modo de esforço configurável nos modelos GPT-5.x

Phi-4 e MAI: modelos pequenos para edge e tarefas simples

Modelos de parceiros (Llama, Mistral, DeepSeek, Cohere): controle e custo

GPT-5.6

Premium, multimodal

Raciocínio

Esforço de raciocínio

Phi-4

Pequeno e rápido

Open source

Llama, Mistral, DeepSeek, Claude

CrITÉrios de escolha de modelo

Qualidade: aderência à tarefa, raciocínio


Custo: $\$/1k \text{ tokens} \times \text{volume previsto}$

Latência: tempo de resposta tolerável

Contexto: quanto contexto a tarefa exige?



Anatomia de um bom prompt



Padrões de prompt

Zero-shot: sem exemplos — para tarefas simples

Few-shot: 1-5 exemplos — calibra o estilo/saída

Chain-of-Thought: 'pense passo a passo' — para raciocínio

Persona: 'você é um especialista em...' — direciona estilo

Zero-shot

Direto ao ponto

Few-shot

Aprende pelo exemplo

Chain-of-Thought

Raciocínio explícito

Persona

Estilo direcionado

Antipadrões — o que evitar

‘Faça da melhor forma possível’ sem definir critério

Falta de contexto ou restrições

Mistura de papéis em um único turn (instrução + dados)


Prompt enorme quando um curto e claro resolveria

Esperar que o modelo adivinhe formato de saída

Não faça assim

- “Me ajuda com isso” → não
- Sem contexto → não
- Sem formato → não
- Crie um TEMPLATE

Hands-on: Microsoft.Extensions.AI + prompts em C#



Hands-on guiado em sala

1. `dotnet add package Microsoft.Extensions.AI (10.9.0)`
2. `dotnet add package Microsoft.Extensions.AI.OpenAI (10.9.0)`
3. Configurar `IChatClient` apontando para o Foundry (`/openai/v1`)
4. Few-shot via `List<ChatMessage>`
5. Structured output: `GetResponseAsync<T>()` com record

Como construir o projeto da aula



Do zero ao dotnet run

1. `dotnet --version` → precisa responder 10.x
2. `dotnet restore` → `dotnet build` na pasta da solução
3. `copy Properties\launchSettings.template.json Properties\launchSettings.json`
4. Preencher `FOUNDRY_ENDPOINT` e `FOUNDRY_MODEL`
5. `az login --tenant <tenant-id>` → `dotnet run`

Compilou e quebrou em runtime? `dotnet nuget why <csproj> OpenAI`

Um projeto = um pivô do pacote OpenAI. Não misture `Azure.AI.*` com `Microsoft.Extensions.AI.OpenAI`.

Recap da aula

LLMs preveem tokens

Probabilístico, não busca

4 partes de um prompt

Contexto, tarefa, restrição, formato

Padrões: zero/few/CoT/persona

Cada um para um caso

Modelo certo p/ tarefa certa

Comece pelo mini

Quiz da aula



Questionário ao vivo — 5 questões

5 questões objetivas sobre LLMs e prompts

Discussão das alternativas

Justificativa do gabarito

Quiz — Pergunta 1 de 5



O que é a janela de contexto de um modelo?

- A) O tempo máximo que o modelo pode levar para responder
- B) O total de tokens que entram e saem em uma única chamada
- C) A quantidade de conversas simultâneas suportadas
- D) O período em que o modelo lembra de você entre sessões

Quiz — Resposta 1 de 5



B) O total de tokens que entram e saem em uma única chamada

É um orçamento de tokens compartilhado entre prompt, histórico e resposta.

Estourar a janela não dá erro elegante: o conteúdo mais antigo simplesmente sai.

E cada token dentro dela é cobrado, a cada chamada.

Quiz — Pergunta 2 de 5



Qual é o papel da mensagem 'system' numa conversa?

- A) Registrar logs para auditoria
- B) Definir comportamento, papel e restrições que valem para toda a conversa
- C) Guardar a resposta anterior do modelo
- D) Informar ao serviço qual deployment usar

Quiz — Resposta 2 de 5



B) Definir comportamento, papel e restrições que valem para toda a conversa

A system é a instrução persistente: persona, formato, limites, tom.

user é a pergunta da vez; assistant é o que o modelo já respondeu.

Regras de negócio que valem sempre pertencem à system, não repetidas em cada user.

Quiz — Pergunta 3 de 5



3

Zero-shot devolve markdown livre e você precisa de um formato fixo. Qual é a intervenção mais barata?

- A) Trocar por um modelo maior
- B) Dar exemplos do formato desejado no prompt (few-shot)
- C) Baixar a temperature para 0
- D) Fazer fine-tuning do modelo

Quiz — Resposta 3 de 5



B) Dar exemplos do formato desejado no prompt (few-shot)

Few-shot ensina o formato por demonstração, sem treinar nada e sem custo de infraestrutura.

Temperature 0 reduz variação, mas não ensina formato.

Fine-tuning só se justifica quando prompt e exemplos já falharam em escala.

Quiz — Pergunta 4 de 5



4

Temperature 0 garante que a mesma pergunta sempre devolva exatamente a mesma resposta?

- A) Sim, é determinístico por definição
- B) Não — reduz muito a variação, mas não garante determinismo
- C) Sim, desde que o modelo seja o mesmo
- D) Não, porque temperature não afeta a amostragem

Quiz — Resposta 4 de 5



B) Não — reduz muito a variação, mas não garante determinismo

Temperature 0 escolhe sempre o token mais provável, o que aproxima do determinismo.

Ainda assim, batching, versão de modelo e aritmética de ponto flutuante introduzem variação.

Se o seu teste depende de igualdade exata de string, ele é frágil por construção.

Quiz — Pergunta 5 de 5



Qual antipadrão de prompt aparece com mais frequência?

- A) Prompt curto demais para a tarefa
- B) Pedir várias tarefas diferentes numa instrução só, sem separar
- C) Usar mensagem system
- D) Dar exemplos de saída

Quiz — Resposta 5 de 5



B) Pedir várias tarefas diferentes numa instrução só, sem separar

Instrução acumulada — resumir, classificar, traduzir e formatar de uma vez — degrada tudo.

Separar em etapas (ou em chamadas) quase sempre melhora, e fica avaliável.

Prompt curto nem sempre é problema; prompt ambíguo é.

Desafio + próxima aula

Biblioteca de prompts encapsulados em classes/records
C#

Cada prompt: nome, objetivo, modelo, parâmetros e exemplo

Entrega: 24h antes da Aula 3

Próxima aula: Foundry SDK e chat client

Por que

Reusabilidade de prompts

O que

5 prompts

Quando

24h antes da Aula 3

Próximo

Foundry SDK + chat