

Conceitos de RAG, Embeddings e Azure AI Search

Versão .NET 10 LTS / C# 14 — 3 horas

Agenda da aula

Por que RAG existe

Componentes do padrão RAG

Embeddings e busca vetorial

Azure AI Search como vector store

Hands-on: indexar corpus pequeno

Por quê

Componentes

Embeddings

Search

Hands-on

Por que RAG existe?

LLM tem 'corte de conhecimento' (não sabe do mundo recente)

LLM não conhece dados privados da sua empresa

Alucinação acontece quando o modelo 'preenche lacunas'

RAG injeta contexto relevante no prompt — fundamenta a resposta

Sem RAG

Conhecimento fixo no modelo
Pode alucinar com dados privados
Resposta não auditável
Atualizar = retreinar

Com RAG

Conhecimento dinâmico (índice)
Resposta fundamentada (grounded)
Citações e auditabilidade
Atualizar = reindexar

Componentes do padrão RAG

Ingestão

Chunking

Embedding

Indexação

Retrieval

Generation

Embeddings em uma frase

Vetor numérico de N dimensões representando significado

Distância vetorial $\approx$ similaridade semântica

Modelos: text-embedding-3-small (1536d), large (3072d)

MESMO modelo para indexar e para buscar (compatibilidade)

Vetores semânticos

- “cachorro” $\rightarrow$ [0.1, -0.4, ...]
- “cão” $\rightarrow$ [0.1, -0.4, ...] muito próximo!
- “banco” $\rightarrow$ distante de ambos
- Cosseno mede similaridade

Busca vetorial × keyword × híbrida

Vetorial (semântica)

- Captura significado
- Encontra sinônimos
- Pode ignorar termos exatos importantes
- Funciona bem com perguntas conversacionais

Keyword + Híbrida

- BM25 acerta termos exatos
- Híbrida = vetorial + BM25
- + Semantic ranking para reordenar
- Melhor de dois mundos

Azure AI Search — o vector store

Índices com campos texto + campos vetoriais

Vetorização integrada (Foundry Models como skill)

Skillsets para enriquecimento (OCR, idioma, PII)

Filtros, facets, autocomplete

RBAC nativo + filtros de segurança

Documentos

Fontes diversas

Skillset

Enriquecimento (OCR, embeddings)

Índice

Texto + vetores + metadados

Query

Vetorial / híbrida / semantic

Estratégias de chunking

Tamanho fixo (token-based) — simples, mas quebra contexto

Por sentença / parágrafo — preserva semântica

Semantic chunking — agrupa por similaridade

Hierárquico (parent/child) — busca em chunk pequeno + retorna pai

Fixo

Token count

Sentença

Preserva meaning

Semantic

Agrupa similar

Hierárquico

Parent/child


Trade-offs de chunk size

Pequeno (200 tokens): preciso, mas perde contexto

Médio (500-1000): equilíbrio típico

Grande (2000+): rico mas ruidoso

Overlap (50-100 tokens) atenua quebras de contexto




Filtros de segurança e ACL

Metadados ricos (departamento, nível, data)

Filtros de query por usuário (RBAC consciente)

Document-level ACL via campos de filtro

Trimming antes de o chunk chegar ao LLM



Demo ao vivo: AI Search

Criar índice vetorial

Inserir documento via SDK

Executar busca vetorial

Resultado com score de relevância


Índice

Inserir doc

Busca

Resultado

Hands-on: RAG básico em C# com Azure.Search.Documents



Hands-on guiado em sala

1. `dotnet add package Azure.Search.Documents (12.0.0, GA — não traz o pacote OpenAI)`
2. `dotnet add package Microsoft.Extensions.AI + .OpenAI (10.9.0)`
3. `FieldBuilder` + `[VectorSearchField]` geram o índice a partir da classe `Chunk`
4. `IEmbeddingGenerator<string, Embedding<float>>` — 1 lote na indexação, 1 por pergunta
5. `VectorizedQuery` + `SemanticSearchOptions` = busca híbrida com reranking
6. Script `provisionar-ai-search.ps1` cria o serviço e concede os 2 papéis

Como construir o projeto da aula



Do zero ao dotnet run

1. `dotnet --version` → precisa responder 10.x
2. `dotnet restore` → `dotnet build` na pasta da solução
3. `copy Properties\launchSettings.template.json Properties\launchSettings.json`
4. Preencher `FOUNDRY_ENDPOINT` e `FOUNDRY_MODEL`
5. `az login --tenant <tenant-id>` → `dotnet run`

Compilou e quebrou em runtime? `dotnet nuget why <csproj> OpenAI`

Um projeto = um pivô do pacote OpenAI. Não misture `Azure.AI.*` com `Microsoft.Extensions.AI.OpenAI`.

Comparação ao vivo: com × sem RAG

Mesma pergunta no playground

Sem RAG: alucinação ou ‘não sei’

Com RAG: resposta fundamentada + citação

Discussão da diferença

Sem RAG

“Não tenho essa informação”

Ou alucina detalhes

Sem citações

Confiança baixa

Com RAG

Resposta direta com dados internos

[1] [2] linkando para chunks

Auditável

Confiança alta

Recap da aula

RAG resolve memória

Conhecimento privado e atual

Embeddings + chunking

Coração do retrieval

Azure AI Search

Vector store maduro

Híbrida + semantic

Elevam qualidade

Quiz da aula



Questionário ao vivo — 5 questões

5 questões sobre RAG e embeddings

Discussão das alternativas

Justificativa do gabarito

Quiz — Pergunta 1 de 5



1

Por que RAG existe?

- A) Para reduzir o custo por token da chamada ao modelo
- B) Para aterrar a resposta em conteúdo que o modelo não viu no treino
- C) Para acelerar a inferência do modelo
- D) Para substituir a necessidade de prompt engineering

Quiz — Resposta 1 de 5



B) Para aterrar a resposta em conteúdo que o modelo não viu no treino

O modelo não conhece seus documentos internos nem o que mudou depois do treino.

RAG recupera trechos relevantes e os injeta no contexto, junto da pergunta.

Efeito colateral bem-vindo: dá para citar a fonte.

Quiz — Pergunta 2 de 5



O que é um embedding?

- A) Um resumo do texto gerado pelo modelo
- B) Um vetor numérico cuja proximidade reflete proximidade de significado
- C) O identificador único do documento no índice
- D) A versão comprimida do documento para economizar armazenamento

Quiz — Resposta 2 de 5



B) Um vetor numérico cuja proximidade reflete proximidade de significado

Textos com sentido próximo ficam próximos no espaço vetorial, mesmo sem palavras em comum. É isso que permite achar 'reembolso de viagem' buscando por 'devolução de despesa'. O embedding não é reversível: não dá para reconstruir o texto a partir dele.

Quiz — Pergunta 3 de 5



3

Quando a busca híbrida vence a busca puramente vetorial?

- A) Sempre — híbrida é estritamente melhor
- B) Quando a consulta tem termos exatos: códigos, SKUs, nomes próprios, siglas
- C) Somente em índices com menos de mil documentos
- D) Quando não há embeddings disponíveis

Quiz — Resposta 3 de 5



B) Quando a consulta tem termos exatos: códigos, SKUs, nomes próprios, siglas

Busca vetorial captura sentido, mas erra em identificadores literais.

Keyword acerta o literal e erra o sinônimo. Híbrida soma os dois e reordena.

Custa um pouco mais de latência — daí não ser automática em todo cenário.

Quiz — Pergunta 4 de 5



Chunks muito grandes prejudicam o RAG por quê?

- A) Estouram o limite de tamanho do índice
- B) Diluem o sinal: o trecho relevante vem cercado de contexto irrelevante
- C) Impedem o uso de filtros de metadados
- D) Tornam impossível citar a fonte

Quiz — Resposta 4 de 5



B) Diluem o sinal: o trecho relevante vem cercado de contexto irrelevante

O embedding de um chunk grande é uma média — e média de muitos assuntos não se parece com nenhum.

Chunks pequenos demais têm o problema oposto: perdem o contexto que dá sentido à frase.

Por isso se testa chunking com o corpus real, não no chute.

Quiz — Pergunta 5 de 5



Como impedir que um usuário receba, via RAG, um trecho de documento que ele não pode ler?

- A) Instruindo o modelo, no prompt, a não revelar conteúdo restrito
- B) Filtrando por ACL/metadados na consulta, antes de o trecho chegar ao modelo
- C) Criptografando os embeddings no índice
- D) Reduzindo o top-k da busca

Quiz — Resposta 5 de 5



B) Filtrando por ACL/metadados na consulta, antes de o trecho chegar ao modelo

Segurança por instrução no prompt não é segurança — é sugestão, e cai no primeiro jailbreak. O filtro tem de acontecer na recuperação: o que o usuário não pode ver não entra no contexto. Guarde o identificador de permissão como metadado no momento da indexação.

Desafio + próxima aula

Microserviço de ingestão em .NET 10 (Minimal API)

Documentos sem dados sensíveis de terceiros

Lista de 5 perguntas reais que se espera responder

Próxima aula: RAG end-to-end + avaliação automatizada

Por que

Você precisa de corpus na A5

O que

Documentos + perguntas

Quando

24h antes da Aula 5

Próximo

RAG end-to-end