

Construindo soluções RAG end-to-end no Microsoft Foundry

Versão .NET 10 LTS / C# 14 — 3 horas

Agenda da aula

Galeria do corpus dos participantes

Pipeline RAG no Foundry (portal e SDK)

Hybrid search + semantic ranking

Avaliação automática (groundedness, relevance, retrieval)

Hands-on: RAG completo + métricas

Corpus

Pipeline

Ranking

Avaliação

Hands-on

Galeria do corpus dos participantes

Diversidade de domínios (RH, vendas, técnico)

Variedade de formato (PDF, DOCX, MD)

5 perguntas alvo por aluno

Discussão dos critérios de seleção

Galeria da turma

- *Corpus de RH (políticas)* • *Corpus técnico (manuais)* • *Corpus comercial (FAQ)* • *Corpus pessoal (notas)*

Pipeline RAG no Foundry — 3 caminhos


Portal ('Add your data')

Mais rápido para POC
Sem código
Limites de configuração
Bom para validar viabilidade

SDK (Python/.NET)

Mais flexível
Pipeline customizável
Integra com sua app
Recomendado para produção

‘Add your data’ — passo a passo



Citações e grounding

Cada chunk usado retorna em 'sources'

Renderizar como [1], [2], com links clicáveis

Aumenta confiança do usuário (resposta auditável)

Fundamental para auditoria e compliance

UX de citações

- Resposta: 'O prazo de garantia é 12 meses [1]' • [1] aponta para → política-garantia.pdf p.3 • Usuário clica → vê o trecho exato • Confiança ↑↑↑


Hybrid search + semantic ranking

Hybrid: vetorial + BM25 em paralelo

Semantic ranker: reordena os resultados por significado

Tipicamente +5 a +15 pontos de relevance

Custo extra mínimo, ganho geralmente vale




Foundry IQ: knowledge sources e knowledge bases

Camada unificada de conhecimento para agentes

Multi-fonte com query plan automático

SharePoint, Bing, Storage, custom

Quando faz sentido: agente que precisa de várias fontes




Agentic retrieval e knowledge bases

LLM planeja subqueries (decompõe a pergunta)

Execução paralela de múltiplas queries

Resposta estruturada com citações por chunk

Mais caro, mais robusto — pesar trade-off



Avaliação de qualidade RAG

Groundedness

A resposta está fundamentada nos chunks?

Relevance

A resposta é relevante à pergunta?

Retrieval

Os chunks recuperados são bons?

Answer correctness

A resposta está correta? (gold)


Hands-on: RAG end-to-end em C# com avaliação



Hands-on guiado em sala

1. Estender API mínima da Aula 4 com /ask
2. VectorQuery + SemanticConfiguration em C#
3. Resposta com citações dos chunks utilizados
4. Microsoft.Extensions.AI.Evaluation.Quality (10.9.0) para evaluators
5. Tunar top-k de 3 → 5 → 10

Como construir o projeto da aula



Do zero ao dotnet run

1. `dotnet --version` → precisa responder 10.x
2. `dotnet restore` → `dotnet build` na pasta da solução
3. `copy Properties\launchSettings.template.json Properties\launchSettings.json`
4. Preencher `FOUNDRY_ENDPOINT` e `FOUNDRY_MODEL`
5. `az login --tenant <tenant-id>` → `dotnet run`

Compilou e quebrou em runtime? `dotnet nuget why <csproj> OpenAI`

Um projeto = um pivô do pacote OpenAI. Não misture `Azure.AI.*` com `Microsoft.Extensions.AI.OpenAI`.

Trade-offs custo × qualidade



Recap da aula

Pipeline completo

Ingestão → Geração

Hybrid + semantic

Ganhos fáceis

Avaliação contínua

Não opcional

Cluster analysis

Diagnóstico estruturado

Quiz da aula



Questionário ao vivo — 5 questões

5 questões sobre RAG end-to-end

Discussão das alternativas

Justificativa do gabarito

Quiz — Pergunta 1 de 5



O que a métrica de groundedness avalia?

- A) Se a resposta agradou o usuário
- B) Se a resposta se sustenta nos trechos recuperados, sem inventar
- C) Se os trechos recuperados são relevantes para a pergunta
- D) Se a resposta foi rápida o bastante

Quiz — Resposta 1 de 5



B) Se a resposta se sustenta nos trechos recuperados, sem inventar

Groundedness olha resposta × contexto recuperado: o que foi afirmado está no material?

Relevance olha pergunta × resposta; retrieval olha pergunta × trechos recuperados.

Uma resposta pode ser relevante e mesmo assim não estar aterrada — é o caso perigoso.

Quiz — Pergunta 2 de 5



2

Aumentar o top-k de 3 para 10 melhora a qualidade do RAG?

- A) Sempre — mais contexto é sempre melhor
- B) Depende: melhora o recall, mas dilui o sinal e encarece cada chamada
- C) Nunca — top-k acima de 5 degrada qualquer sistema
- D) Só melhora se o chunk for pequeno

Quiz — Resposta 2 de 5



B) Depende: melhora o recall, mas dilui o sinal e encarece cada chamada

Mais trechos aumentam a chance de o certo estar lá, e também a de ruído entrar junto.

Cada chunk extra é contexto pago em toda pergunta.

Por isso se mede: 3, 5 e 10 com o mesmo conjunto de perguntas, e compara-se groundedness.

Quiz — Pergunta 3 de 5



Por que citações são parte do produto, e não enfeite?

- A) Porque a lei exige em todo sistema de IA
- B) Porque permitem ao usuário verificar a resposta e revelam quando o sistema errou
- C) Porque reduzem o consumo de tokens
- D) Porque melhoram o ranking da busca

Quiz — Resposta 3 de 5



B) Porque permitem ao usuário verificar a resposta e revelam quando o sistema errou

Sem citação, uma resposta errada é indistinguível de uma certa aos olhos do usuário.

Com citação, o erro fica auditável — e o time descobre se o problema foi recuperação ou geração.

É também o que sustenta confiança em domínios regulados.

Quiz — Pergunta 4 de 5



4

O agentic retrieval difere da busca clássica em quê?

- A) Usa um índice diferente, otimizado para agentes
- B) O modelo decompõe a pergunta e faz várias buscas encadeadas em vez de uma
- C) Dispensa embeddings
- D) Roda sempre no cliente, sem chamar o serviço

Quiz — Resposta 4 de 5



B) O modelo decompõe a pergunta e faz várias buscas encadeadas em vez de uma

Perguntas compostas ('compare a política de 2024 com a de 2026') não se resolvem numa consulta só. O agente planeja, busca em etapas e reúne o resultado. Custa mais chamadas e mais latência — vale quando a pergunta realmente é composta.

Quiz — Pergunta 5 de 5



Sua avaliação de RAG piorou depois de uma mudança. Onde olhar primeiro?

- A) No modelo de geração — provavelmente mudou de versão
- B) Nas métricas separadas de recuperação e de geração, para saber qual etapa quebrou
- C) No custo por chamada
- D) Na temperatura usada na geração

Quiz — Resposta 5 de 5



B) Nas métricas separadas de recuperação e de geração, para saber qual etapa quebrou

Groundedness caiu mas retrieval continua bom: o problema é na geração ou no prompt.

Retrieval caiu: o problema é chunking, embeddings, filtros ou o índice.

Sem separar as duas medidas, o diagnóstico vira adivinhação.

Desafio + próxima aula

Otimização RAG em C# com Plotly.NET ou Markdown

Documentar configurações testadas

Tabela ou gráfico antes/depois

Próxima aula: agentes e Microsoft Agent Framework

Por que

Pratica iteração de qualidade

O que

RAG otimizado + relatório

Quando

24h antes da Aula 6

Próximo

Agentes + MAF